


## 第 13 节课习题

1.

某时刻，SLAM 系统中相机和路标点的观测关系如下图所示，其中  $\xi$  表示相机姿态， $L$  表示观测到的路标点。当路标点  $L$  表示在世界坐标系下时，第  $k$  个路标被第  $i$  时刻的相机观测到，重投影误差为  $r(\xi_i, L_k)$ 。另外，相邻相机之间存在运动约束，如 IMU 或者轮速计等约束。



1) 绘制上述系统的信息矩阵  $\Lambda$

我们总共有 9 个观测量和 6 个状态量，所以雅可比  $J$  维度为  $9 \times 6$ ，信息矩阵  $J^T W^{-1} J$  维度为  $6 \times 6$ 。


首先信息矩阵对角线上的元素不为空。

观测包括第  $i$  个姿态观测到  $j$  个路标点，以及第  $i$  个姿态与其相邻姿态之间的运动约束观测，如 IMU 或者轮速计约束。其中  $i \in \{1, 2, 3\}, j \in \{1, 2, 3\}$ 。

信息矩阵内下标为  $(i, i+1)$  和  $(i+1, i)$  的元素不为空，因为第  $i$  个姿态和第  $i+1$  个姿态之间存在约束。

信息矩阵内下标为  $(i, 3+j)$  和  $(3+j, i)$  的矩阵块不为空，当第  $i$  个姿态可以观测到  $j$  个路标点。


可绘制出信息矩阵  $\Lambda$  如下：



2) 绘制相机  $\xi_1$  被 marg 以后的信息矩阵  $\Lambda'$

当姿态  $\xi_1$  被 marg 之后，可以将原来的信息矩阵分成对应的四个矩阵块  $\Lambda_{\beta\beta}$ ,  $\Lambda_{\alpha\beta}$ ,  $\Lambda_{\beta\alpha}$ ,  $\Lambda_{\alpha\alpha}$

利用边缘化公式  $\Lambda' = \Lambda_{\alpha\alpha} - \Lambda_{\alpha\beta} \Lambda_{\beta\beta}^{-1} \Lambda_{\beta\alpha}$  可绘制出姿态  $\xi_1$  被 marg 之后的信息矩阵  $\Lambda'$  如下：



我们发现路标点  $L_1$  和  $L_2$  之间本来独立，但是姿态  $\xi_1$  被 marg 之后， $L_1$  和  $L_2$  之间彼此相关，导致信息矩阵变得更加稠密。

## 2. 证明信息矩阵和协方差的逆之间的关系

文献[1]证明了对于任意高斯随机变量构成的矩阵，它的信息矩阵  $H$  等于协方差的逆：

Consider a Gaussian random vector  $\theta$  with mean  $\theta^*$  and covariance matrix  $\Sigma_\theta$  so its joint probability density function (PDF) is given by:

$$p(\theta) = (2\pi)^{-\frac{N_\theta}{2}} |\Sigma_\theta|^{-\frac{1}{2}} \exp \left[ -\frac{1}{2} (\theta - \theta^*)^T \Sigma_\theta^{-1} (\theta - \theta^*) \right] \quad (A.1)$$

The objective function can be defined as its negative logarithm:

$$J(\theta) \equiv -\ln p(\theta) = \frac{N_\theta}{2} \ln 2\pi + \frac{1}{2} \ln |\Sigma_\theta| + \frac{1}{2} (\theta - \theta^*)^T \Sigma_\theta^{-1} (\theta - \theta^*) \quad (A.2)$$

which is a quadratic function of the components in  $\theta$ . By taking partial differentiations with respect to  $\theta_l$  and  $\theta_{l'}$ , the  $(l, l')$  component of the Hessian matrix can be obtained:

$$\mathcal{H}^{(l,l')}(\theta^*) = \left. \frac{\partial^2 J(\theta)}{\partial \theta_l \partial \theta_{l'}} \right|_{\theta=\theta^*} = (\Sigma_\theta^{-1})^{(l,l')} \quad (A.3)$$

so the Hessian matrix is equal to the inverse of the covariance matrix:

$$\mathcal{H}(\theta^*) = \Sigma_\theta^{-1} \quad (A.4)$$

以上就是文献中给出的证明。我们有任意高斯变量矩阵  $\theta$ ，假设其均值为  $\theta^*$ 。对高斯变量矩阵的概率密度函数  $p(\theta)$  取负对数作为 objective function，令负对数最小化的  $\theta$  取值就可以令该取值处的概率密度最大。我们求取该 objective function 对  $\theta$  的二次导数，就是 Hessian 矩阵。求二次导后，我们发现信息矩阵  $H$  正好就是协方差的逆。由于求得的  $H$  矩阵不包含  $\theta$ ，说明信息矩阵与均值  $\theta^*$  无关。

另外由于 Hessian 矩阵包含了所有随机变量的条件信息(conditional information)，所以称它为信息矩阵。信息矩阵对角线上的元素代表了 objective function 在对应方向上的曲率。信息矩阵是条件概率的方差，而它的倒数，也就是协方差矩阵正好是随机变量之间的边际概率的方差。

论文中还给出了求取数值上的信息矩阵的方法：

the diagonal elements are given by:

$$\begin{aligned} \mathcal{H}^{(l,l)}(\theta^*) &= \left[ \frac{\partial}{\partial \theta_l} \left( \frac{\partial J(\theta)}{\partial \theta_l} \right) \right]_{\theta=\theta^*} \\ &\approx \frac{1}{\Delta \theta_l} \left[ \left. \frac{\partial J(\theta)}{\partial \theta_l} \right|_{\theta=\theta^*+\Delta \theta_l/2} - \left. \frac{\partial J(\theta)}{\partial \theta_l} \right|_{\theta=\theta^*-\Delta \theta_l/2} \right] \\ &\approx \frac{1}{\Delta \theta_l} \left[ \frac{J(\theta^* + \Delta \theta_l) - J(\theta^*)}{\Delta \theta_l} - \frac{J(\theta^*) - J(\theta^* - \Delta \theta_l)}{\Delta \theta_l} \right] \\ &= \frac{J(\theta^* + \Delta \theta_l) - 2J(\theta^*) + J(\theta^* - \Delta \theta_l)}{(\Delta \theta_l)^2} \end{aligned} \quad (A.5)$$

where  $\Delta \theta_l$  is a vector with all elements being zero except the  $l$ th element equal to a properly selected step  $\Delta \theta_l (> 0)$ :

$$\Delta \theta_l = [0, \dots, 0, \Delta \theta_l, 0, \dots, 0]^T \quad (A.6)$$

Furthermore, the off-diagonal elements can be computed as follows:

$$\begin{aligned} \mathcal{H}^{(l,l')}(\theta^*) &= \left[ \frac{\partial}{\partial \theta_{l'}} \left( \frac{\partial J(\theta)}{\partial \theta_l} \right) \right]_{\theta=\theta^*} \\ &\approx \frac{1}{2\Delta \theta_{l'}} \left[ \left. \frac{\partial J(\theta)}{\partial \theta_l} \right|_{\theta=\theta^*+\Delta \theta_{l'}} - \left. \frac{\partial J(\theta)}{\partial \theta_l} \right|_{\theta=\theta^*-\Delta \theta_{l'}} \right] \\ &\approx \frac{1}{2\Delta \theta_{l'}} \left[ \frac{J(\theta^* + \Delta \theta_l + \Delta \theta_{l'}) - J(\theta^* - \Delta \theta_l + \Delta \theta_{l'})}{2\Delta \theta_l} \right. \\ &\quad \left. - \frac{J(\theta^* + \Delta \theta_l - \Delta \theta_{l'}) - J(\theta^* - \Delta \theta_l - \Delta \theta_{l'})}{2\Delta \theta_l} \right] \\ &= \frac{1}{4\Delta \theta_l \Delta \theta_{l'}} [J(\theta^* + \Delta \theta_l + \Delta \theta_{l'}) - J(\theta^* + \Delta \theta_l - \Delta \theta_{l'}) \\ &\quad - J(\theta^* - \Delta \theta_l + \Delta \theta_{l'}) + J(\theta^* - \Delta \theta_l - \Delta \theta_{l'})] \end{aligned} \quad (A.7)$$

where  $\Delta \theta_l$  and  $\Delta \theta_{l'}$  are vectors with zero elements except the  $l$ th and  $l'$ th elements equal to  $\Delta \theta_l$  and  $\Delta \theta_{l'}$ , respectively.

### 3. 补充作业代码中单目 Bundle Adjustment 信息矩阵的计算，并输出奇异值

根据《视觉 SLAM 十四讲》，纯粹的视觉 SLAM 中相机姿态之间，以及路标点之间互相没有关联，只在相机姿态和路标点之间存在关联，信息矩阵  $H$  的稀疏性如下：

$$J = \begin{bmatrix} J_{11} \\ J_{12} \\ J_{13} \\ J_{14} \\ J_{23} \\ J_{24} \\ J_{25} \\ J_{26} \end{bmatrix} = \begin{bmatrix} C_1 & C_2 & P_1 & P_2 & P_3 & P_4 & P_5 & P_6 \\ \text{[blocks]} & & & & & & & \\ & & & & & & & \\ & & & & & & & \\ & & & & & & & \\ & & & & & & & \\ & & & & & & & \\ & & & & & & & \end{bmatrix} \quad H = J^T J = \begin{bmatrix} \text{[blocks]} & & & & & & & \\ & \text{[blocks]} & & & & & & \\ & & \text{[blocks]} & & & & & \\ & & & \text{[blocks]} & & & & \\ & & & & \text{[blocks]} & & & \\ & & & & & \text{[blocks]} & & \\ & & & & & & \text{[blocks]} & \\ & & & & & & & \text{[blocks]} \end{bmatrix}$$

根据书中给出的公式，我们最小化重投影误差之和来求出最佳的相机姿态和路标点：

$$\xi^* = \arg \min_{\xi} \frac{1}{2} \sum_{i=1}^n \left\| u_i - \frac{1}{s_i} K \exp(\xi^{\wedge}) P_i \right\|_2^2.$$

残差对姿态的  $2 \times 6$  雅可比为：

$$\begin{aligned} \frac{\partial e}{\partial \xi} &= \lim_{\delta \xi \rightarrow 0} \frac{e(\delta \xi \oplus \xi)}{\delta \xi} = \frac{\partial e}{\partial P'} \frac{\partial P'}{\partial \delta \xi} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{bmatrix} [I, -P'^{\wedge}] \\ &= - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} & -\frac{f_x X' Y'}{Z'^2} & f_x + \frac{f_x X^2}{Z'^2} & -\frac{f_x Y'}{Z'} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} & -f_y - \frac{f_y Y'^2}{Z'^2} & \frac{f_y X' Y'}{Z'^2} & \frac{f_y X'}{Z'} \end{bmatrix} \end{aligned}$$

残差对路标点的  $2 \times 3$  雅可比为：

$$\frac{\partial e}{\partial P} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{bmatrix} R$$

该单目 SLAM 中我们总共有 10 个相机姿态  $\text{poseNums} = 10$ ，20 个路标点  $\text{featureNums} = 20$ 。代码中使用了内外 for 循环，显然假设了每个相机姿态都观测到了所有路标点。另外假设每次观测的不确定度一致，导致权重矩阵  $W$  为单位阵。而且很显然，原代码中定义的残差为重投影的值减去观测值，所以代码中的  $\text{jacobian\_Ti}$  和  $\text{jacobian\_uv\_Pc}$  的计算公式与以上书中的公式相差一个负号。

我们接下来根据公式补充信息矩阵  $H = J^T W^{-1} J$ 。首先信息矩阵  $H$  对角线上的矩阵块不为空，对应相机姿态和路标点的对角线上下标为  $(i * 6, i * 6)$  和  $(\text{poseNums} * 6 + j * 6, \text{poseNums} * 6 + j * 6)$  的矩阵块的维度分别为  $6 \times 6$  和  $3 \times 3$ 。

其次信息矩阵内非对角线，下标为  $(i * 6, \text{poseNums} * 6 + j * 3)$  和  $(\text{poseNums} * 6 + j * 3, i * 6)$  的维度  $6 \times 3$  和  $3 \times 6$  的矩阵块不为空，任意第  $i$  个姿态可以观测到第  $j$  个路标点。代码如下：

```
38
39 // 随机数生成三维特征点
40 std::default_random_engine generator;
41 std::vector<Eigen::Vector3d> points;
42 for(int j = 0; j < featureNums; ++j)
43 {
44     std::uniform_real_distribution<double> xy_rand(0, 4.0);
45     std::uniform_real_distribution<double> z_rand(0.8, 10.0);
46     double tx = xy_rand(generator);
47     double ty = xy_rand(generator);
48     double tz = z_rand(generator);
49
50     Eigen::Vector3d Pw(tx, ty, tz);
51     points.push_back(Pw);
52
53     for (int i = 0; i < poseNums; ++i) {
54         Eigen::Matrix3d Rcw = camera_pose[i].Rwc.transpose();
55         Eigen::Vector3d Pc = Rcw * (Pw - camera_pose[i].twc);
56
57         double x = Pc.x();
58         double y = Pc.y();
59         double z = Pc.z();
60         double z_2 = z * z;
61         Eigen::Matrix<double, 2, 3> jacobian_uv_Pc;
62         jacobian_uv_Pc << fx/z, 0, -x * fx/z_2,
63             0, fy/z, -y * fy/z_2;
64         Eigen::Matrix<double, 2, 3> jacobian_Pj = jacobian_uv_Pc * Rcw;
65         Eigen::Matrix<double, 2, 6> jacobian_Ti;
66         jacobian_Ti << -x * y * fx/z_2, (1 + x*x/z_2)*fx, -y/z*fx, fx/z, 0, -x * fx/z_2,
67             -(1+y*y/z_2)*fy, x*y/z_2 * fy, x/z * fy, 0, fy/z, -y * fy/z_2;
68
69         H.block(startRow + i*6, startCol + j*6, blockRows: 6, blockCols: 6) += jacobian_Ti.transpose() * jacobian_Ti;
70         H.block(startRow + poseNums*6 + j*3, startCol + poseNums*6 + j*3, blockRows: 3, blockCols: 3) += jacobian_Pj.transpose() * jacobian_Pj;
71         H.block(startRow + i*6, startCol + poseNums*6 + j*3, blockRows: 6, blockCols: 3) += jacobian_Ti.transpose() * jacobian_Pj;
72         H.block(startRow + poseNums*6 + j*3, startCol + i*6, blockRows: 3, blockCols: 6) += jacobian_Pj.transpose() * jacobian_Ti;
73     }
74 }
```

代码输出信息矩阵的奇异值如下:

```
0.00763381
0.00734249
0.00701361
0.00634341
0.00608493
0.00547299
0.0053236
0.00520788
0.00502341
0.0048434
0.00451083
0.0042627
0.00386223
0.00351651
0.00302963
0.00253459
0.00230246
0.00172459
0.000422374
3.21708e-17
2.06732e-17
1.43188e-17
7.66992e-18
6.08423e-18
6.05715e-18
3.94363e-18
Process finished with exit code 0
```

我们发现奇异值最后 7 维接近于 0，表明零空间的维度为 7，因为单目 SLAM 中 7 自由度不可观，包括 6 自由度姿态 + 尺度。

参考文献:

[1] Relationship between the Hessian and Covariance Matrix for Gaussian Random Variables, Bayesian Methods for Structural Dynamics and Civil Engineering, Ka-Veng Yuen